Emotion Is All You Need

Reconocimiento de emociones en el habla con representaciones auto-supervisadas y ensembles

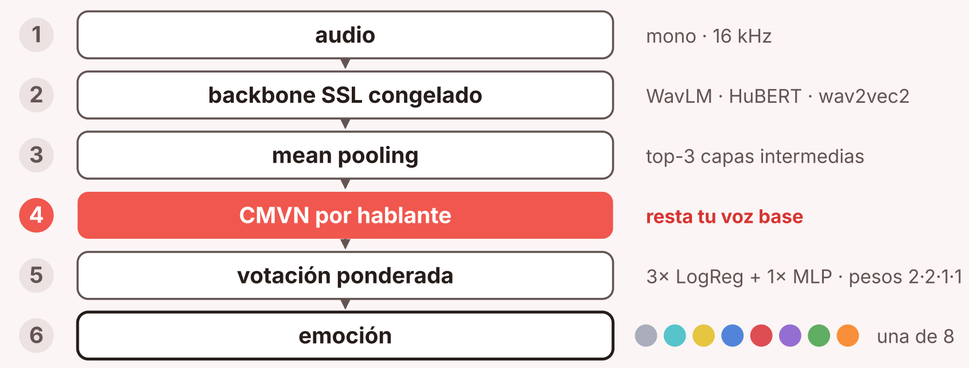
Bautista García · Tomás González — Universidad de San Andrés · I302 Aprendizaje Automático y Aprendizaje Profundo · AI Fest 2026

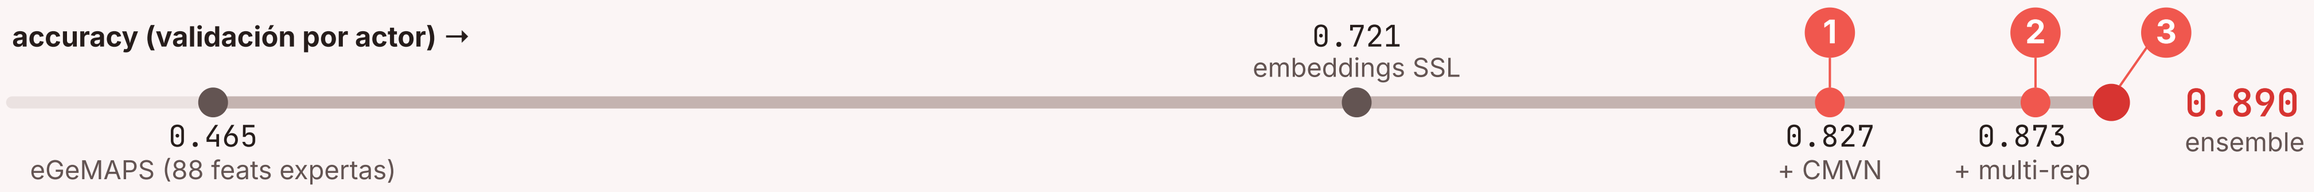
Las 8 que detecta → neutral · calma · feliz · triste · enojo · miedo · disgusto · sorpresa



La voz te delata dos veces

- La voz mezcla tres cosas: **qué** decís, **quién** sos y **cómo** estás. La emoción vive en la tercera.
- Pero la identidad **domina la señal**: un modelo descuidado aprende voces, no emociones.
- **RAVDESS**: 1440 audios · 24 actores · 8 emociones. Validación **GroupKFold-5 por actor**: jamás evaluamos con una voz vista en entrenamiento.





Las features expertas ya viven en las aprendidas: concatenar eGeMAPS a los embeddings aporta apenas +0.005. Los saltos grandes son las tres lecciones ↓

1 Tu identidad es ruido: restátela.

El análisis exploratorio lo mostró crudo: entre hablantes hay más variación que entre emociones. **CMVN por hablante** expresa cada audio como desviación del punto neutro de su propia voz — justo donde vive la emoción.

$$\tilde{x} = \frac{x - \mu_s}{\sigma_s}$$



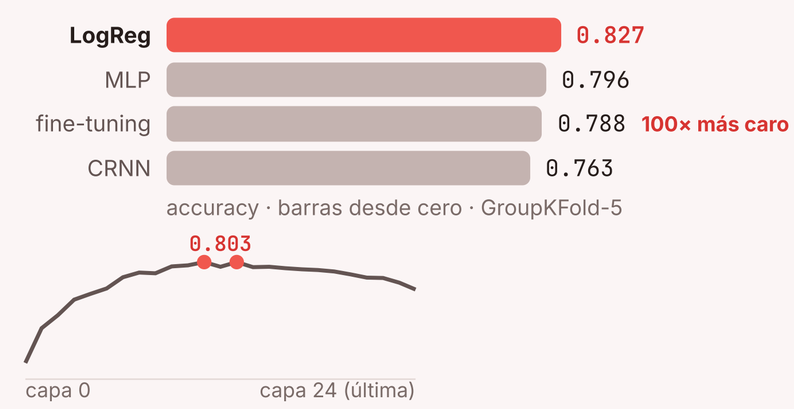
+7 pts

la mejora individual más grande de todo el trabajo — sin tocar el modelo



LogReg · wav2vec2 capa 8 · GroupKFold-5





y dentro del transformer, las capas **intermedias** le ganan a las finales (WavLM-large)

2 Con 1440 audios, lo simple gana.

Misma representación, cuatro modelos: la **regresión logística** (bien regularizada: acá $d \gg n$) le gana al MLP, al CRNN con atención y hasta al **fine-tuning end-to-end** de 317M de parámetros. Capacidad extra = varianza, no señal.

3 La diversidad vale más que la fuerza.

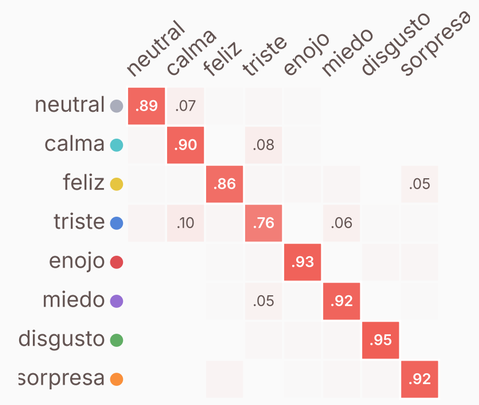
4 votantes: LogReg sobre WavLM (×2), HuBERT (×2) y wav2vec2 (×1) + un MLP (×1) entrenado con **pseudo-hablantes** — cada audio deformado en velocidad y ruido simula una voz nueva.

La prueba: le dimos HuBERT al MLP y mejoró **solo**… pero el ensemble **empeoró**. Se volvió más fuerte y más parecido al resto: aportó menos información nueva.

	ANTES	DESPUÉS	
MLP solo	0.874	0.883	mejora ✓
Ensemble	0.890	0.887	empeora ✗

0.890

accuracy · 0.888 macro-F1 · speaker-disjoint



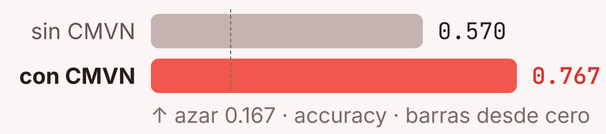
recall por fila · out-of-fold

lo que queda: **triste↔calma** (baja activación) y **feliz↔sorpresa** (alta)



¿Aprende emoción de verdad? Lo probamos en alemán 🇩🇪

Mismo modelo, **sin reentrenar**, sobre EMODB (454 audios, 6 clases compartidas):



La lección ① también es la herramienta clave contra el cambio de dominio: normalizar por hablante recupera **+20 pts**. El error que queda: **enojo→feliz** (comparten activación alta).



Gobbie está escuchando →

Grabá tu voz en la compu del stand y mirá cómo reacciona en vivo.

Refs: Livingstone & Russo, RAVDESS (PLoS ONE 2018) · Eyben et al., GeMAPS (IEEE TAC 2016) · Baevski et al., wav2vec 2.0 (NeurIPS 2020) · Chen et al., WavLM (IEEE JSTSP 2022) · Hsu et al., HuBERT (IEEE TASLP 2021) · Pepino et al. (Interspeech 2021) · Burkhardt et al., EMODB (Interspeech 2005) · scikit-learn · PyTorch · HuggingFace Transformers