# Emotion Is All You Need

Representaciones auto-supervisadas y ensembles para el reconocimiento de emociones en el habla

Bautista Garcia
Universidad de San Andrés
garciab@udesa.edu.ar

Tomas Gonzalez
Universidad de San Andrés
tgonzalez@udesa.edu.ar

***Resumen*—El reconocimiento de emociones en el habla (SER) busca detectar el estado afectivo de una persona a partir de su voz, con aplicaciones que van de la atención al cliente a la salud. En este trabajo armamos un sistema de SER sobre RAVDESS comparando dos familias de representaciones (las features expertas eGeMAPS y los embeddings auto-supervisados de wav2vec 2.0, WavLM y HuBERT) y una escalera de modelos de complejidad creciente, desde Random Forest y regresión logística hasta redes densas, recurrentes y *fine-tuning* end-to-end. Con validación cruzada estricta por hablante (GroupKFold-5), un ensemble ponderado de clasificadores lineales sobre varios backbones SSL más una red densa entrenada con aumentación de pseudo-hablantes llega a $0{,}890$ de accuracy ($0{,}888$ de macro-F1), partiendo de un baseline de $0{,}465$. La normalización por hablante (CMVN) resultó la mejora individual más grande ($+7$ puntos), y los modelos de mayor capacidad no superaron al enfoque lineal con los datos disponibles. Evaluado sin reentrenar sobre EMODB (en alemán), el sistema conserva $0{,}767$ de accuracy sobre las seis clases compartidas, y de nuevo es CMVN lo que explica la mayor parte de la recuperación frente al cambio de dominio.**

***Index Terms*—reconocimiento de emociones en el habla, aprendizaje auto-supervisado, ensembles, normalización por hablante, cambio de dominio**

## I. Introducción

Detectar la emoción de una persona a partir de su voz tiene aplicaciones bien concretas. En un centro de atención al cliente, por ejemplo, serviría para monitorear cómo evoluciona el ánimo de los agentes a lo largo de sus llamadas y detectar desgaste a tiempo, sin agregar nada a la infraestructura que ya existe, porque las llamadas ya se graban. El desafío técnico es que la señal de voz mezcla qué se dice, quién lo dice y cómo se dice. La emoción vive en el tercer componente, pero los dos primeros, sobre todo la identidad del hablante, dominan la señal acústica. Un sistema entrenado sin cuidado aprende a reconocer voces en lugar de emociones, y falla justo en el escenario de uso real, frente a hablantes que nunca vio.

La entrada de nuestro algoritmo es una señal de audio de voz (mono, a 16 kHz, de duración variable). A partir de ella extraemos una representación de dimensión fija y usamos clasificadores supervisados para predecir una de ocho emociones (neutral, calma, felicidad, tristeza, enojo, miedo, disgusto y sorpresa). Encaramos el trabajo con dos preguntas. Primero, ¿qué representación captura mejor la emoción, las features acústicas expertas o las aprendidas por modelos auto-supervisados (SSL)? Segundo, ¿cuánta capacidad de modelo aguanta un dataset de $\sim$1400 ejemplos? Como extensión, evaluamos el sistema final sin reentrenarlo sobre un corpus en otro idioma (EMODB, en alemán) para medir el efecto del cambio de dominio.

## II. Conjunto de datos y características

### II-A. RAVDESS

Trabajamos con RAVDESS [1], un corpus de 24 actores profesionales (12 mujeres y 12 hombres) que dicen dos frases léxicamente idénticas con acento norteamericano neutro. El canal de habla tiene 1440 audios (8 emociones $\times$ 2 frases $\times$ 2 repeticiones $\times$ 2 intensidades $\times$ 24 actores, con la excepción de la clase neutral, que solo existe en intensidad normal y por eso tiene la mitad de ejemplares). El corpus trae además un canal cantado (1012 audios) que usamos solo en la exploración inicial. Todos los resultados que reportamos son sobre el canal de habla. El desbalance de neutral motiva usar macro-F1 como métrica complementaria y pesos por clase al entrenar.

### II-B. Variables espurias y diseño de splits

El análisis exploratorio mostró que la variación entre hablantes (y entre géneros) en las features prosódicas es comparable o mayor que la variación entre emociones. La identidad es un *confound* directo para la tarea. Como cada actor aporta 60 audios, un split aleatorio por muestra filtraría voces del test al entrenamiento y sobreestimaría el rendimiento. Por eso evaluamos con GroupKFold de 5 particiones agrupando por actor, así ningún hablante aparece a la vez en entrenamiento y evaluación.

Hay un punto que queremos dejar claro. No apartamos un conjunto de test propio de RAVDESS, porque con 24 hablantes reservar actores para un test separado nos dejaba muy pocos para entrenar. Todas las métricas que reportamos son entonces de *validación*, calculadas sobre las predicciones out-of-fold de la validación cruzada. La evaluación sobre EMODB, que el modelo no ve en ningún momento del desarrollo, es nuestro único test realmente externo. La intensidad y el texto, balanceados por diseño en RAVDESS, no necesitaron control extra.

### II-C. Representaciones

Exploramos las dos familias requeridas. **eGeMAPS** [2] son 88 funcionales acústicos por audio (estadísticos de F0, energía, formantes y espectro) extraídos con openSMILE [3], el conjunto experto estándar en SER. Los **embeddings SSL**

son las representaciones internas de wav2vec 2.0 base [4] (95M de parámetros, 12 capas transformer de dimensión 768), WavLM-large [5] y HuBERT-large [6] (ambos de 317M, con 24 capas de dimensión 1024), pre-entrenados sobre miles de horas de habla sin etiquetas. Siguiendo a Pepino et al. [7], tratamos la capa de la que se extrae el embedding como un hiperparámetro a investigar en vez de quedarnos con la última. Como preprocesamiento, todo audio se convierte a mono 16 kHz. Para EMODB aplicamos exactamente el mismo pipeline, sin ninguna adaptación.

### *II-D. EMODB para evaluación cross-corpus*

EMODB [9] tiene 535 audios de 10 actores en alemán con 7 emociones. Seis coinciden con RAVDESS (neutral, felicidad, tristeza, enojo, miedo y disgusto). Descartamos *aburrimiento*, que no tiene equivalente, y evaluamos sobre los 454 audios restantes sin reentrenar ni recalibrar el modelo.

## III. Metodología

### *III-A. De la señal al vector de features*

Un forward por el modelo SSL produce estados ocultos $\mathbf{h}_t^{(\ell)} \in \mathbb{R}^H$ para cada capa $\ell$ y frame $t$ (unos 50 frames por segundo). La representación de un audio en la capa $\ell$ es el promedio temporal (*mean pooling*)

$$\mathbf{x}^{(\ell)} = \frac{1}{T}\sum_{t=1}^{T} \mathbf{h}_t^{(\ell)}, \tag{1}$$

y la representación multi-capa concatena las tres mejores capas del barrido, $\mathbf{x} = [\,\mathbf{x}^{(\ell_1)}; \mathbf{x}^{(\ell_2)}; \mathbf{x}^{(\ell_3)}\,]$.

### *III-B. Normalización por hablante (CMVN)*

Para sacarle a las features la identidad del hablante aplicamos *cepstral mean and variance normalization* por hablante. Si $\boldsymbol{\mu}_s$ y $\boldsymbol{\sigma}_s$ son la media y el desvío de las features del hablante $s$,

$$\tilde{\mathbf{x}} = (\mathbf{x} - \boldsymbol{\mu}_s) \oslash \boldsymbol{\sigma}_s, \tag{2}$$

con $\oslash$ la división elemento a elemento. Cada audio queda representado como su desviación respecto del punto neutro de su propio hablante, que es justo donde vive la emoción. Las estadísticas se calculan por hablante dentro de cada conjunto, sin cruzar información entre folds.

### *III-C. Modelos*

Probamos una escalera de modelos de complejidad creciente. Los hiperparámetros salieron de la misma validación cruzada.

El **Random Forest** (el baseline requerido) usa de 300 a 400 árboles con pesos de clase balanceados.

Para la **regresión logística**, como acá $d \gg n$ (hasta 3072 features para 1440 audios), usamos regularización fuerte con $C$=0,01 ($C$=0,1 en la comparación inicial, de dimensión menor), estandarización previa y pesos de clase balanceados.

El **MLP** tiene dos capas ocultas (512 y 256) con ReLU, batch-norm de entrada y dropout de 0,3, y se entrena con Adam ($\eta$=$10^{-3}$, weight decay $10^{-4}$), batch de 64 y *early stopping* con paciencia 10 sobre una validación interna estratificada del 15 % del fold de entrenamiento.

El **CRNN** busca aprovechar la dinámica temporal que el mean pooling descarta, trabajando sobre los frames sin promediar. Tiene una Conv1D (256 canales, kernel 5), después una BiGRU (128) y al final *attention pooling*, donde el peso de cada frame se aprende como $\alpha_t = \mathrm{softmax}_t(\mathbf{w}^\top \mathbf{o}_t)$ y el contexto es $\mathbf{c} = \sum_t \alpha_t \mathbf{o}_t$. Cumple el requisito de combinar capas convolucionales, recurrentes y densas.

El **fine-tuning end-to-end** ajusta el backbone SSL completo con una cabeza de clasificación, con lr de $2 \cdot 10^{-5}$ y warmup del 10 % (lo estándar para transformers pre-entrenados), el encoder convolucional congelado, batch de 4 a 8 y early stopping.

### *III-D. Aumentación de pseudo-hablantes*

Con 24 hablantes nomás, generamos variantes de cada audio que suenan como otra persona, usando perturbación de velocidad (factores 0,9 y 1,1, que también corren el pitch) y ruido gaussiano (SNR 20 dB). Los embeddings de las variantes heredan la etiqueta del original y se suman únicamente al entrenamiento, y solo si su hablante de origen pertenece al fold de train. Si no, la misma voz (deformada) aparecería de los dos lados del split.

### *III-E. Ensemble*

El modelo final combina $K$ clasificadores por votación blanda ponderada

$$P(y \mid a) = \frac{1}{\sum_k w_k} \sum_{k=1}^{K} w_k \, P_k(y \mid a). \tag{3}$$

Los cuatro votantes son regresiones logísticas sobre WavLM-large (top-3 capas, $w$=2), HuBERT-large ($w$=2) y wav2vec2-base ($w$=1), más el MLP con aumentación ($w$=1), cuya entrada es la concatenación de los embeddings de WavLM-large y wav2vec2-base. Todos los votantes trabajan sobre features con CMVN. Los pesos los elegimos por validación cruzada entre variantes discretas.

### *III-F. Protocolo de evaluación*

La métrica principal es accuracy y la complementaria macro-F1, $\mathrm{F1}_{\text{macro}} = \frac{1}{C}\sum_c \mathrm{F1}_c$, que promedia sin ponderar por soporte y por eso castiga ignorar a la clase minoritaria (neutral). Las dos se calculan sobre las predicciones out-of-fold del GroupKFold-5 por actor. Como dijimos en la Sección II-B, son métricas de validación y no hay un test set separado de RAVDESS. Para EMODB el modelo final se entrena sobre todo RAVDESS speech y se evalúa sin reentrenamiento.

## IV. Experimentos, resultados y discusión

### *IV-A. Features expertas vs. aprendidas*

La Tabla I compara los dos modelos base sobre las tres representaciones iniciales. Se ven dos cosas. Primero, los embeddings SSL superan por mucho a eGeMAPS con los dos

Tabla I
MODELOS BASE × REPRESENTACIÓN (SPEECH, GROUPKFOLD-5).

| Modelo | Representación | Accuracy | Macro-F1 |
|---|---|---|---|
| Random Forest | eGeMAPS (88) | 0,465 | 0,449 |
| Random Forest | wav2vec capa 8 (768) | 0,588 | 0,576 |
| Random Forest | combinado (856) | 0,597 | 0,582 |
| LogReg | eGeMAPS (88) | 0,518 | 0,511 |
| LogReg | wav2vec capa 8 (768) | 0,721 | 0,715 |
| LogReg | combinado (856) | **0,727** | **0,721** |

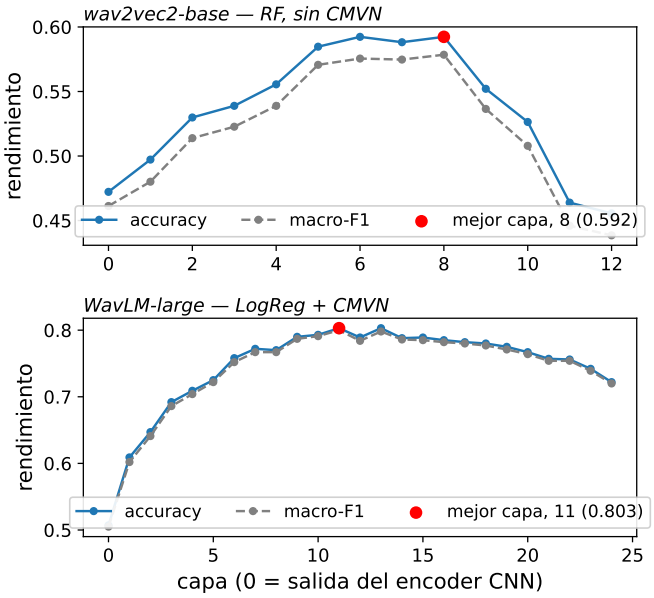



Figura 1. Rendimiento por capa. Arriba se muestra wav2vec2-base (evaluado con RF, sin CMVN) y abajo WavLM-large (LogReg + CMVN). En los dos casos las capas intermedias superan a las finales.

clasificadores. Segundo, la regresión logística, con la regularización adecuada, le gana al Random Forest en el espacio de alta dimensión. Combinar eGeMAPS con wav2vec aporta poco ya desde esta etapa, primera señal de una redundancia que después se confirma.

### *IV-B. ¿Qué capa del modelo SSL?*

La Figura 1 muestra el barrido por capa para los dos backbones. El patrón se repite en ambos. El rendimiento sube hasta las capas intermedias y cae hacia las últimas, que están especializadas en el objetivo de pre-entrenamiento (predecir unidades enmascaradas) y descartan información prosódica. Nos quedamos con las tres mejores capas de cada backbone (8-6-7 en wav2vec2-base, 13-11-10 en WavLM-large y 13-14-12 en HuBERT-large) y las concatenamos.

### *IV-C. El efecto de normalizar por hablante*

La Tabla II aísla las dos mejoras de representación. CMVN por hablante es la mejora individual más grande de todo el trabajo, con +7 puntos de accuracy sin tocar el modelo (0,732 → 0,803). Eso confirma que buena parte del error venía del confound de identidad. La concatenación multi-capa suma

Tabla II
EFECTO DE CMVN Y MULTI-CAPA (LOGREG $C$=0,01, WAV2VEC2-BASE).

| Representación | Accuracy | Macro-F1 |
|---|---|---|
| capa 8 | 0,732 | 0,727 |
| capa 8 + CMVN | 0,803 | 0,797 |
| top-3 capas | 0,736 | 0,731 |
| top-3 + CMVN | 0,822 | 0,815 |
| top-3 + eGeMAPS + CMVN | **0,827** | **0,821** |

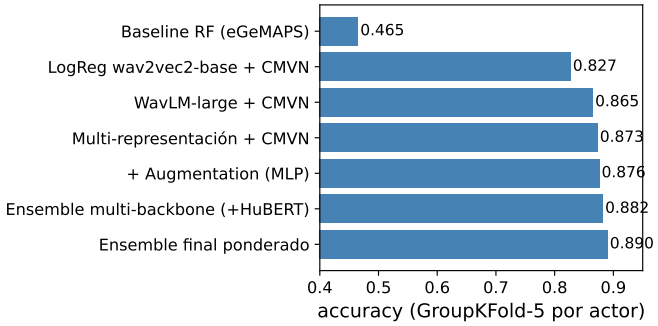



Figura 2. Recorrido de optimización, del baseline al ensemble final.

unos 2 puntos más y eGeMAPS apenas medio punto, señal de que la información experta ya está casi toda contenida en los embeddings.

### *IV-D. Las redes neuronales no ganan*

Acá vino la primera sorpresa. Sobre la misma representación, el MLP quedó por debajo del modelo lineal (0,796 contra 0,827) y el CRNN sobre secuencias frame-level, aun con acceso a la dinámica temporal completa, quedó más abajo todavía (0,763). Con 1440 ejemplos la capacidad extra se convierte en varianza, y los dos modelos sobreajustan sus folds a pesar del dropout, el weight decay, el early stopping y los pesos de clase. El resultado más caro confirmó el patrón. El fine-tuning end-to-end de WavLM-large con aumentación llegó a 0,788 en promedio (4 folds), lejos del enfoque de features congeladas y con un costo computacional dos órdenes de magnitud mayor. Con pocos datos, tocar los 317M de parámetros es peor que dejarlos quietos.

### *IV-E. Optimización del sistema final*

La Tabla III resume el camino desde el mejor modelo individual hasta el ensemble. Pasar a WavLM-large aporta +3,7 puntos sobre wav2vec2-base y combinar representaciones suma +0,9. La aumentación de pseudo-hablantes beneficia sobre todo al MLP (0,847 → 0,876), consistente con que las redes son las que más sufren la escasez de hablantes. El ensemble de tres backbones llega a 0,882, y con el MLP aumentado más la ponderación final alcanza **0,890** / 0,888 de macro-F1. La Figura 2 resume el recorrido completo desde el baseline. La Figura 3 muestra la matriz de confusión del sistema final. Los errores que quedan se concentran en pares de activación parecida, tristeza–calma (baja activación) y felicidad–sorpresa (alta).

Tabla III
OPTIMIZACIÓN AVANZADA Y ENSEMBLE (SPEECH, GROUPKFOLD-5). "BASE" ABREVIA WAV2VEC2-BASE.

| Sistema | Accuracy | Macro-F1 |
|---|---|---|
| WavLM-large top-3 + CMVN (LogReg) | 0,864 | 0,863 |
| WavLM + base + eGeMAPS + CMVN | 0,873 | 0,871 |
| MLP (WavLM+base) + aumentación | 0,876 | — |
| Ensemble 3 backbones | 0,882 | 0,880 |
| Ensemble + MLP aum. | 0,888 | 0,886 |
| Ensemble final ponderado (2-2-1-1) | **0,890** | **0,888** |
| Fine-tuning WavLM-large + aum. | 0,788 | 0,782 |

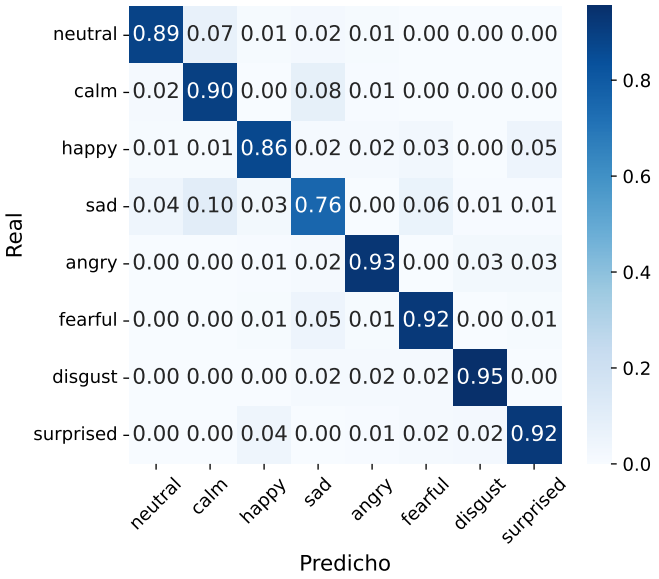



Figura 3. Matriz de confusión (recall por clase) del ensemble final sobre RAVDESS speech, predicciones out-of-fold.

### *IV-F. Diversidad sobre fuerza individual*

Un experimento posterior ilustra por qué funciona el ensemble, y es el hallazgo que más nos gustó del trabajo. El MLP usa como entrada WavLM+base. Al enriquecerlo con HuBERT su rendimiento individual mejoró ($0{,}874 \rightarrow 0{,}883$, su mejor valor aislado), pero el ensemble *empeoró* ($0{,}890 \rightarrow 0{,}887$). ¿Por qué? El MLP se volvió más parecido a los votantes lineales, que ya usan HuBERT, y al promediar aportó menos información nueva. En un ensemble importan más los errores no correlacionados que la fuerza de cada miembro. El votante más débil pero distinto complementa mejor que el más fuerte pero redundante.

En cuanto al sobreajuste, la validación speaker-disjoint elimina la vía principal (memorizar voces), y la regularización fuerte, el early stopping y la aumentación controlan la capacidad. Igual somos conscientes de un riesgo más fino. Hicimos decenas de comparaciones contra el mismo protocolo de validación cruzada, y elegir el mejor sistema con esas mismas métricas puede sobreajustar la selección. Por eso importa la evaluación cross-corpus que sigue, que es el único número del trabajo que el proceso de desarrollo no pudo contaminar.

Tabla IV
CAMBIO DE DOMINIO DE RAVDESS A EMODB (454 AUDIOS, 6 CLASES).

| Variante | Accuracy | Macro-F1 |
|---|---|---|
| Sin CMVN | 0,570 | 0,578 |
| Con CMVN por hablante | **0,767** | **0,787** |

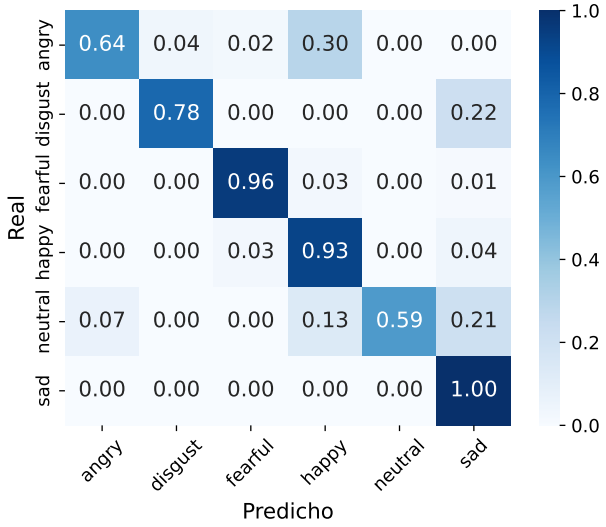



Figura 4. Matriz de confusión (recall por clase) sobre EMODB con CMVN. El error dominante es enojo → felicidad, pares de alta activación.

### *IV-G. Generalización cross-corpus (EMODB)*

La Tabla IV muestra qué pasa al aplicar el sistema final, sin reentrenar, a un corpus en alemán. Sin ninguna adaptación el accuracy cae de $0{,}890$ a $0{,}570$. Es una caída grande, pero queda muy por encima del azar ($1/6 \approx 0{,}167$), señal de que los embeddings SSL capturan algo de la emoción paralingüística que no es exclusivo del inglés. Aplicar CMVN con las estadísticas de los hablantes de EMODB recupera casi 20 puntos ($0{,}767$), la mitad del camino de vuelta al rendimiento in-domain y con la intervención más barata disponible. La Figura 4 muestra que el error dominante que queda es enojo clasificado como felicidad (36 de 127 casos). Tiene sentido acústico, porque las dos comparten activación alta (energía y F0 elevados) y se distinguen por la valencia, que es la dimensión más difícil de SER.

## V. CONCLUSIÓN Y TRABAJO FUTURO

Construimos un sistema de SER que mejora de $0{,}465$ a $0{,}890$ de accuracy speaker-disjoint sobre RAVDESS. Las lecciones principales no son las que esperábamos al arrancar. Primero, la ganancia dominante no vino de modelos más grandes sino de controlar el confound de hablante (CMVN, $+7$ puntos). Segundo, con $\sim$1400 ejemplos los modelos lineales regularizados le ganan a MLP, CRNN y fine-tuning end-to-end, y las redes solo aportan como votante diverso de un

ensemble. Tercero, en el ensemble la diversidad de errores vale más que el rendimiento individual de cada miembro. La evaluación cross-corpus sobre EMODB ($0{,}767$ sin reentrenar) sugiere que el sistema captura emoción genuina y que normalizar por hablante es también la herramienta clave frente al cambio de dominio.

Con más tiempo exploraríamos fine-tuning con corpus multilingües más grandes (donde el enfoque end-to-end debería revertir su desventaja), calibración y adaptación ligera al dominio destino (con unos pocos audios por hablante alcanza para estimar CMVN, como mostró EMODB) y la dimensión de valencia, que concentra los errores restantes.

## REFERENCIAS


[1] S. R. Livingstone y F. A. Russo, "The Ryerson Audio-Visual Database of Emotional Speech and Song (RAVDESS)," *PLoS ONE*, vol. 13, no. 5, e0196391, 2018.

[2] F. Eyben *et al.*, "The Geneva Minimalistic Acoustic Parameter Set (GeMAPS) for voice research and affective computing," *IEEE Trans. Affective Computing*, vol. 7, no. 2, pp. 190–202, 2016.

[3] F. Eyben, M. Wöllmer y B. Schuller, "openSMILE: the Munich versatile and fast open-source audio feature extractor," en *Proc. ACM Multimedia*, 2010, pp. 1459–1462.

[4] A. Baevski, H. Zhou, A. Mohamed y M. Auli, "wav2vec 2.0: A framework for self-supervised learning of speech representations," en *Proc. NeurIPS*, 2020.

[5] S. Chen *et al.*, "WavLM: Large-scale self-supervised pre-training for full stack speech processing," *IEEE J. Sel. Topics Signal Process.*, vol. 16, no. 6, pp. 1505–1518, 2022.

[6] W.-N. Hsu *et al.*, "HuBERT: Self-supervised speech representation learning by masked prediction of hidden units," *IEEE/ACM Trans. Audio, Speech, Lang. Process.*, vol. 29, pp. 3451–3460, 2021.

[7] L. Pepino, P. Riera y L. Ferrer, "Emotion recognition from speech using wav2vec 2.0 embeddings," en *Proc. Interspeech*, 2021, pp. 3400–3404.

[8] C. Doğdu, T. Kessler, D. Schneider, M. Shadaydeh y S. R. Schweinberger, "A comparison of machine learning algorithms and feature sets for automatic vocal emotion recognition in speech," *Sensors*, vol. 22, no. 19, 7561, 2022.

[9] F. Burkhardt, A. Paeschke, M. Rolfes, W. Sendlmeier y B. Weiss, "A database of German emotional speech," en *Proc. Interspeech*, 2005, pp. 1517–1520.

[10] F. Pedregosa *et al.*, "Scikit-learn: Machine learning in Python," *J. Mach. Learn. Res.*, vol. 12, pp. 2825–2830, 2011. Se utilizaron además PyTorch y HuggingFace Transformers.